

Projet : Prédiction du Loyer Résidentiel à Bujumbura

1. Introduction

Cette analyse exploratoire des données (Exploratory Data Analysis – EDA) a pour objectif de comprendre la structure du jeu de données avant toute opération de prétraitement. L'EDA permet d'identifier les problèmes de qualité des données, d'étudier les distributions des variables, de détecter les valeurs aberrantes et d'analyser les relations entre les variables explicatives et la variable cible.

Toutes les décisions prises lors de la phase de **Data Preparation** seront directement justifiées par les observations présentées dans ce rapport.

2. Présentation du Dataset

Le jeu de données est composé de **510 observations** et de **12 variables** représentant les caractéristiques de maisons résidentielles situées à Bujumbura.

La variable cible est :

LoyerMensuel_BIF

Les variables explicatives sont :

- Chambres
- Salon
- SalleDeBainInterieure
- Parking
- Meuble
- Jardin
- Superficie_m2
- DistanceRoute_m
- Quartier
- AgeMaison

La colonne **IdentifiantMaison** est uniquement un identifiant unique.

Observation

Le dataset contient à la fois des variables numériques et des variables catégorielles.

Interprétation

Cette combinaison est adaptée à un problème de régression supervisée.

Engineering Decision

La colonne **IdentifiantMaison** sera supprimée avant l'entraînement puisqu'elle n'apporte aucune information prédictive.

3. Qualité des données

L'analyse montre que le dataset contient **510 lignes** et **12 colonnes**.

Les variables sont correctement typées.

Aucune valeur manquante n'est présente dans :

- IdentifiantMaison
- LoyerMensuel_BIF

En revanche, les autres variables possèdent chacune **25 valeurs manquantes**.

Observation

Toutes les variables explicatives comportent exactement **25 valeurs manquantes**, soit environ **4,9 %** des observations.

Interprétation

Ce faible pourcentage indique que le dataset reste de bonne qualité. Les valeurs manquantes sont réparties sur plusieurs variables et n'affectent pas la variable cible.

Engineering Decision

Le dataset sera conservé. Les valeurs manquantes seront imputées plutôt que supprimées afin d'éviter une perte d'informations.

4. Analyse des valeurs manquantes

Le calcul des valeurs manquantes montre la situation suivante :

Variable	Valeurs manquantes
Chambres	25
Salon	25
SalleDeBainInterieure	25
Parking	25
Meuble	25
Jardin	25
Superficie_m2	25
DistanceRoute_m	25
Quartier	25
AgeMaison	25

Observation

Toutes les variables explicatives présentent exactement le même nombre de valeurs manquantes.

Interprétation

Cette situation laisse penser que certaines observations sont incomplètes de manière uniforme. Il est probable que les données manquantes soient de type **MCAR** ou **MAR**, ce qui autorise une imputation sans introduire un biais majeur.

Engineering Decision

Pour la phase de préparation :

- Variables numériques → imputation par la médiane.
- Variables catégorielles → imputation par le mode.

5. Analyse de la variable cible (LoyerMensuel_BIF)

Le loyer mensuel représente la variable que le modèle devra prédire.

L'étude de l'histogramme et du boxplot permet d'évaluer :

- la forme de la distribution ;
- la dispersion des loyers ;
- la présence de valeurs aberrantes.

Observation

Le loyer présente une forte variabilité. Certaines maisons affichent des loyers très élevés, ce qui crée une légère asymétrie vers la droite.

Le boxplot met en évidence quelques valeurs extrêmes correspondant aux logements les plus chers.

Interprétation

Ces observations sont cohérentes avec la réalité du marché immobilier. Les maisons de luxe ou situées dans des quartiers prestigieux expliquent ces loyers élevés.

Engineering Decision

Les valeurs extrêmes seront conservées, car elles représentent des situations réelles. Une transformation logarithmique ($\log_{10}$) pourra être testée lors de la modélisation si elle améliore les performances.

6. Analyse des variables numériques

6.1 Chambres

Observation

La majorité des logements possède un nombre moyen de chambres. Quelques maisons disposent d'un nombre beaucoup plus élevé.

Interprétation

Plus une maison possède de chambres, plus son prix est susceptible d'être élevé.

Engineering Decision

La variable sera conservée.

6.2 Superficie_m2

Observation

La superficie présente une dispersion importante avec quelques valeurs très élevées.

Interprétation

Ces valeurs correspondent probablement à de grandes villas ou propriétés.

Engineering Decision

Les observations seront conservées. Une normalisation sera envisagée pour les modèles sensibles à l'échelle des variables.

6.3 DistanceRoute_m

Observation

La distribution est asymétrique. Certaines maisons sont très éloignées de la route principale.

Interprétation

La proximité d'une route peut influencer la valeur locative.

Engineering Decision

La variable sera conservée.

6.4 AgeMaison

Observation

La plupart des maisons sont relativement récentes, mais quelques-unes sont beaucoup plus anciennes.

Interprétation

L'âge de la maison peut avoir un effet positif ou négatif sur le loyer selon son état et son emplacement.

Engineering Decision

La variable sera conservée.

7. Analyse des variables catégorielles

Salon

Les logements possédant un salon sont majoritaires.

Décision : conserver la variable.

SalleDeBainInterieure

La majorité des maisons possède une salle de bain intérieure.

Décision : conserver.

Parking

Le parking est présent pour une grande partie des logements.

Décision : conserver.

Jardin

Les maisons avec jardin présentent généralement un loyer plus élevé.

Décision : conserver.

Meuble

Les logements meublés sont susceptibles d'avoir un prix supérieur.

Décision : conserver.

Quartier

Cette variable présente plusieurs catégories correspondant aux différents quartiers de Bujumbura.

Observation

Le nombre de catégories est élevé.

Interprétation

Le quartier constitue probablement l'un des facteurs les plus influents sur le prix du loyer.

Engineering Decision

La variable sera encodée (One-Hot Encoding ou autre méthode adaptée au modèle).

8. Analyse des corrélations

La matrice de corrélation montre les relations entre les variables numériques.

Observation

Une corrélation positive est attendue entre **Chambres** et **Superficie_m2**. Les autres variables présentent des corrélations plus faibles.

Interprétation

Une corrélation élevée entre deux variables peut entraîner une multicolinéarité pour les modèles linéaires.

Engineering Decision

La multicolinéarité sera vérifiée avant l'entraînement des modèles de régression linéaire.

9. Relation entre les variables et le loyer

Les scatter plots et boxplots montrent les relations entre les variables explicatives et le loyer.

Observation

Le loyer augmente généralement avec :

- le nombre de chambres ;
- la superficie ;
- la présence d'un jardin ;
- la présence d'un parking ;
- le fait que le logement soit meublé.

Interprétation

Ces variables semblent être des prédicteurs importants.

Engineering Decision

Elles seront conservées dans le modèle.

10. Synthèse des décisions pour la Data Preparation

Analyse EDA	Observation	Décision de Data Preparation
IdentifiantMaison	Variable technique sans information métier	Supprimer la colonne
Valeurs manquantes	25 valeurs manquantes dans chaque variable explicative	Imputer les variables numériques par la médiane et les variables catégorielles par le mode
Variable cible	Distribution légèrement asymétrique avec quelques valeurs extrêmes	Tester une transformation logarithmique si nécessaire
Outliers	Présents mais cohérents avec la réalité du marché	Conserver les observations et utiliser des méthodes robustes
Variables numériques	Échelles différentes	Appliquer une normalisation ou une standardisation selon le modèle utilisé
Variables catégorielles	Présence de variables binaires et de la variable <code>Quartier</code>	Encoder les variables catégorielles avant l'entraînement
Corrélations	Corrélation possible entre certaines variables numériques	Vérifier la multicolinéarité pour les modèles linéaires
Relations avec la cible	Plusieurs variables influencent le loyer	Conserver ces variables pour la modélisation

11. Conclusion

L'analyse exploratoire montre que le jeu de données est **globalement de bonne qualité** et adapté à la construction d'un modèle de régression. Les principales actions prévues pour la phase de **Data Preparation** sont :

- suppression de la colonne `IdentifiantMaison` ;
- imputation des valeurs manquantes ;
- encodage des variables catégorielles ;
- normalisation des variables numériques si le modèle le nécessite ;
- vérification de l'intérêt d'une transformation logarithmique de la variable cible ;
- contrôle de la multicolinéarité avant les modèles linéaires.

Toutes ces décisions découlent directement des observations réalisées pendant l'EDA et serviront de base à la phase suivante du projet.